



市面上絕大部份講對齊
的東西都是空談…
但這篇不是！

對齊：
[模型 to 資料] 以及 [演算法 to 世界]

- PeterWolf

- **AI 對齊性的定義與重要性**
- **語言模型中的對齊挑戰**
- **對齊技術的演進**
- **實際案例與應用**

Garbage in, Garbage out. (GIGO)

 + Machine Learning = 

Data

 + Artificial Intelligence = 


Data

 + Generative AI = 



Data

 + Agentic AI = 

Data



Garbage in, Garbage out. (GIGO)



什麼是對齊 (alignment)

對齊 (Alignment) 是指確保人工智慧系統的行為與人類的價值觀、意圖和目標保持一致的過程。

為什麼重要？

- **確保 AI 系統安全可靠**
- **避免意外或有害的行為**
- **建立使用者信任**
- **符合倫理與法律規範**

語言模型 / 語言科技對齊的三個層面

- **技術對齊**
 - 模型輸出符合預期功能
 - 準確理解使用者意圖
- **價值對齊**
 - 符合人類道德價值
 - 尊重文化差異
- **行為對齊**
 - 避免有害內容生成
 - 拒絕不當請求

語言模型的對齊挑戰

- **主要困難**
 - **規模問題**：模型參數數以億計，行為難以完全預測
 - **多義性**：語言具有模糊性，意圖判斷困難
 - **文化差異**：不同文化背景的價值觀差異
 - **新興應用**：新的使用場景帶來新的對齊需求
- **實例**
 - **生成偏見內容**
 - **誤解使用者意圖**
 - **產生錯誤事實**

早期對齊方法

- **監督式微調 (Supervised Fine-tuning)**
 - 使用標註資料訓練模型
 - 教導模型「正確」的回應方式
- **限制**
 - 需要大量人工標註
 - 難以涵蓋所有情況
 - 可能過度擬合訓練資料
- **效果**
 - ✓ 提升基本任務表現 (也就是輕微地過擬合)
 - ✗ 對新情況泛化能力有限

近代 (五年內) 強化學習與人類回饋 p1

- RLHF (Reinforcement Learning from Human Feedback)
- 工作原理：
 - 收集人類偏好資料
 - 訓練獎勵模型
 - 使用強化學習優化語言模型
- 優勢
 - 更好地捕捉人類偏好
 - 提升回應品質
 - 減少有害輸出

近代 (五年內) 強化學習與人類回饋 p2

- 缺點

- 成本高昂且難以擴展

- 需要大量人類標註者持續提供回饋
 - 標註品質直接影響模型表現
 - 隨著模型能力提升, 評估難度增加
 - 長期維護成本很高

- 人類偏好的問題

- 主觀性: 不同標註者可能有不同偏好
 - 不一致性: 同一標註者在不同時間可能給出不同評分
 - 偏見: 標註者本身的偏見會傳遞給模型
 - 文化差異: 難以代表全球多元觀點

- 獎勵函數的局限

- 過度優化 (Reward Hacking): 模型可能學會「討好」獎勵模型而非真正對齊
 - Goodhart 定律: 當獎勵成為目標, 它就不再是好的衡量標準
 - 代理失敗 (Proxy Failure): 獎勵模型無法完美捕捉人類真實偏好

- 能力退化問題

- 過度對齊可能損害模型的基礎能力
 - 模型可能變得過於保守、拒絕合理請求
 - 創造力和多樣性可能下降

近代 (五年內) 強化學習與人類回饋 p3

- 缺點 (續)
 - 短視性偏差
 - 人類標註者傾向偏好「看起來好」的回應
 - 可能忽視長期後果或深層正確性
 - 偏好表面流暢而非實質準確
 - 難以處理複雜場景
 - 需要專業知識的領域 (如醫療、法律) 評估困難
 - 標註者可能無法判斷技術正確性
 - 微妙的倫理困境難以標準化
 - 「對齊稅」 (Alignment Tax)
 - 為了安全性犧牲部分性能
 - 在某些任務上表現可能不如未對齊的模型

對齊的手法：RLHF

- **階段一：監督式微調**
 - 預訓練模型 → 高品質示範資料 → 初步對齊的模型
- **階段二：獎勵模型訓練**
 - 人類評分者比較多的回應 → 訓練獎勵模型 → 學習人類偏好
- **階段三：強化學習優化**
 - 使用 PPO 演算法 → 根據獎勵模型優化 → 最終對齊模型

蛤？ PPO ？

- **PPO（近端策略優化）是一種在強化學習中使用的策略梯度演算法，由 OpenAI 於 2017 年提出。它的核心思想是透過限制策略的更新幅度，在保證訓練穩定的同時尋找性能更優的策略。這使得 PPO 比傳統的策略梯度方法更不容易出現訓練不穩定現象。**
- **但相對地，也更容易出現「講不聽」的現象。**

對齊的手法：Constitutional AI

- 概念

- 透過「憲法」(一組原則)指導 AI 行為，使其自我修正

- 方法

- 批評階段：模型識別自己回應的問題
- 修正階段：根據原則改進回應
- 強化學習：基於 AI 回饋進行訓練

- 優勢

- 減少人類標註需求
- 提高一致性
- 可擴展性強

- 缺點

- 顯而易見地…那「一組原則」是誰的原則？

台灣情境的對齊考量

- 在地化需求

- 語言習慣：台灣特有用語、流行語
- 文化價值：民主、多元、尊重隱私
- 法律規範：個資法、數位發展法規

- 期待

- 正確處理**台灣歷史與政治議題**
- 理解在地商業與社會脈絡
 - 資方都是萬惡的
 - 勞方未受照顧
 - UBC 最棒，中華民國萬萬稅
 - 認知失調的社會氣氛
- 符合台灣使用者期待
 - 所以我們在期待什麼？

偏見問題與 (想像中的) 緩解

- 常見偏見類型

- 性別偏見：職業刻板印象
- 種族偏見：不平等的代表性
- 年齡偏見：對不同年齡層的假設
- 地域偏見：城鄉或區域差異

- 緩解策略

- 平衡訓練資料
 - 什麼叫「平衡」？
- 偏見檢測工具
 - 什麼是「偏見」？
- 持續監控與調整
 - 「誰」來調整？
- 多元團隊參與
 - 「誰」付錢給這些多元團隊？
 - 「多元」是「免費」嗎？

事實準確性對齊

- 理論意義：
 - 文化、社會、傳統…這些東西都是文組那些人在搞的，講都講不清楚。在 AI 的時代，我們理工人就是務實、科學、理性，講求事實！（蛤？）
- 挑戰
 - 幻覺 (Hallucination)：生成不實資訊
 - 誰決定什麼是事實？
 - 時效性：知識更新滯後
 - 美國總統是誰？
 - 可驗證性：難以追溯資訊來源
 - 維基一定對嗎？還是 LINE 上的消息比較正確？
- (想像中的) 改進方法
 - 檢索增強生成 (RAG)
 - 引用來源標註
 - 不確定性表達
 - 知識庫整合

安全性與有害內容

- **風險類別**

- **暴力與仇恨言論**
- **個人隱私洩露**
- **詐騙與操縱資訊**
- **不適當內容生成**

- **防護機制**

- **輸入過濾：檢測惡意請求**
- **輸出審查：過濾有害內容**
- **語境理解：區分合理與不當使用**
- **使用者報告：持續改進**

對齊評估

- 評估方法
 - 人類評估
 - 哪一個人類？
 - 自動化指標
 - 對抗性測試
 - 真實世界部署監控
 - 沒有部署到應用場景持續監控改進，就沒有真正的對齊！

對齊的權衡取捨

- 常見衝突
 - 安全 vs 功能：過度限制影響實用性
 - 通用 vs 專用：不同領域的對齊需求差異
 - 全球 vs 在地：普世價值與文化特殊性
- 平衡之道，唯「當責」而已！
 - 可配置的對齊等級（依任務微調細節）
 - 領域專用模型（領域！領域！領域！location, location, location!)
 - 透明的限制說明（具備可解釋性的 NeuroSymbolic AI)
 - 負責任的 AI 架構設計（不是「讓 AI 背鍋負責」！）

未來發展方向

技術趨勢

- **可解釋對齊**：理解為何模型做出特定選擇
- **個人化對齊**：適應個別使用者偏好
- **動態對齊**：可隨社會價值演進而調整（成本可負擔）
- **跨系統對齊**：多個 AI 系統的 Hybrid 協同

結論

在語言科技裡…

- 對齊是一個 Top-down 的必要工程目標
- 對齊可以透過 Top-down + Bottom-up 的 Hybrid 技術實現
- 核心要點
 - ✓ 對齊是 AI 安全的基礎
 - ✓ 技術方法需具備「可持續性」
 - ✓ 需要跨領域合作
 - ✓ 文化脈絡至關重要
 - ✓ 組織企業價值觀亦至關重要